

NHẬN XÉT LUẬN VĂN THẠC SĨ THEO CHẾ ĐỘ /grad

Phát hiện ung thư da trên thiết bị biên sử dụng mô hình học sâu kết hợp chưng cất tri thức

Đánh giá theo chuẩn luận văn thạc sĩ ngành Khoa học Máy tính, trọng tâm: khoảng trống nghiên cứu, phương pháp, baseline, đánh giá, tái lập và mức độ đóng góp.

EXECUTIVE SUMMARY

Overall Assessment

Luận văn có nền tảng kỹ thuật rất tốt cho cấp thạc sĩ. Thiết kế thực nghiệm không dừng ở một cặp teacher-student mà mở rộng thành ma trận $3 \text{ teacher} \times 4 \text{ student}$, dùng 5-fold cross-validation với ràng buộc patient-disjoint, cùng seed và siêu tham số, chỉ thay đổi hàm mất mát giữa nhánh KD và nhánh đối chứng. Đây là một thiết kế mạnh hơn đáng kể so với nhiều luận văn ứng dụng học sâu thông thường, vì nó cố gắng cô lập biến độc lập “chưng cất tri thức” thay vì chỉ báo cáo một mô hình đạt điểm cao.

Điểm thuyết phục nhất của luận văn nằm ở ba lớp bằng chứng: đánh giá trong miền với AUPRC và $\text{pAUC@TPR} \geq 80\%$, đánh giá xuyên miền trên HAM10000, và phân tích công bằng theo tông da trên Fitzpatrick17k. Luận văn cũng có phần triển khai thực tế tương đối hiếm ở đề tài học sâu y tế: export ExecuTorch, kiểm tra tương đương số học, đo latency trên Pixel 6a, đo trạng thái máy nguội và sau 5 phút chạy liên tục, rồi dựng Pareto frontier. Đối với chuẩn bảo vệ thạc sĩ, đây là một công trình có khối lượng thực nghiệm lớn, tư duy phản biện tốt và ý thức rõ về rò rỉ dữ liệu, mất cân bằng lớp, kiểm định thống kê và triển khai biên.

Tuy nhiên, luận văn chưa nên được trình bày như một kết luận lâm sàng mạnh. Tập test trong miền chỉ có 241 ca ác tính và có cấu trúc rất lệch: 377 ảnh PAD nằm khoảng ba phần tư số ca dương. Điều này làm AUPRC toàn tập dễ bị chi phối bởi miền ảnh lâm sàng nhỏ. Ngoài ra, các phát biểu như “KD cải thiện nhất quán”, “lợi ích tỉ lệ nghịch với chất lượng student” và “teacher nào tốt nhất phụ thuộc miền” cần được rào lại rõ hơn về mức độ suy luận thống kê, vì các 12 cặp teacher-student không phải 12 quan sát độc lập. Cuối cùng, nếu mục tiêu là hướng tới hệ thống sàng lọc thật, luận văn cần bổ sung hiệu chuẩn xác suất, chiến lược chọn ngưỡng triển khai, phân tích lỗi ca bệnh và gói tái lập hoàn chỉnh.

Main Strengths

- **Thiết kế thí nghiệm có kiểm soát tốt.** Ma trận $3 \text{ teacher} \times 4 \text{ student}$, 5-fold patient-disjoint, cùng dữ liệu/seed/siêu tham số và chỉ thay loss giữa KD và baseline tạo ra khung so sánh ceteris paribus khá sạch cho một luận văn thạc sĩ.
- **Chọn metric phù hợp với mất cân bằng lớp cực đoan.** Việc dùng AUPRC làm metric chính, $\text{pAUC@TPR} \geq 80\%$ làm metric vận hành, kèm $\text{Sens@90\%Spec}$ và $\text{Sens@95\%Spec}$, là lựa chọn đúng hơn nhiều so với accuracy hoặc AUC-ROC đơn thuần.

- **Ý thức tốt về rò rỉ dữ liệu.** Luận văn nhận diện nguy cơ rò rỉ qua patient_id, metadata đặc quyền và nhãn mô bệnh học; việc gán tiền tố cho bệnh nhân PAD và dùng StratifiedGroupKFold là điểm cộng lớn.
- **Có đánh giá ngoài miền và công bằng.** HAM10000 và Fitzpatrick17k được dùng như hai tầng kiểm chứng độc lập, giúp tránh kết luận chỉ dựa trên tập test nội bộ.
- **Triển khai biên không chỉ là tuyên bố.** Luận văn có export ExecuTorch, kiểm tra tương đương logit, benchmark trên Pixel 6a và phân tích thermal throttling. Đây là bằng chứng triển khai thực tế, không phải chỉ đo FLOPs hoặc kích thước mô hình trên giấy.
- **Phần hạn chế tương đối trung thực.** Tác giả tự nêu rõ cấu trúc bất thường của test set, giới hạn của số lượng teacher và việc KD trong bài toán nhị phân một logit không còn là “dark knowledge” theo nghĩa cổ điển.

Major Weaknesses

- **Bằng chứng trong miền chưa đủ mạnh để gánh các phát biểu tổng quát.** Internal test chỉ có 241 ca dương và AUPRC toàn tập bị chi phối bởi 377 ảnh PAD; vì vậy các kết luận trong miền cần được diễn đạt là hỗ trợ, không phải bằng chứng quyết định.
- **Thiếu hiệu chuẩn xác suất và chiến lược ngưỡng triển khai.** Kết quả HAM10000 cho thấy điểm vận hành không chuyển miền tốt; nếu không có calibration/ECE/Brier và threshold protocol, hệ thống chưa đủ cơ sở để diễn giải rủi ro sàng lọc.
- **Một số suy luận thống kê dùng 12 cặp teacher–student như thể độc lập.** Các cặp dùng chung student, teacher, tập test và pipeline; do đó tương quan $r = -0.963$ nên được trình bày như xu hướng mô tả, không phải kết luận định luật.
- **Khung baseline còn thiếu các đối chứng nén/triển khai thay thế.** Nhánh no-KD là cần thiết nhưng chưa đủ để chứng minh KD là lựa chọn tốt hơn các phương án như label smoothing, pruning, quantization, class-balanced loss hoặc các kiến trúc edge cổ điển.
- **Gói tái lập chưa hoàn chỉnh trong bản luận văn.** Phụ lục siêu tham số rất tốt, nhưng vẫn thiếu repository/commit hash, phiên bản môi trường đầy đủ, script chạy lại và manifest artifact để người khác tái dựng kết quả.

DETAILED REVIEW

Issue 1: Kết luận trong miền bị giới hạn bởi cấu trúc test set lệch ca dương

Category: Evaluation / Data Integrity

Severity: High

Evidence: Luận văn báo cáo tập test giữ lại có 62.040 ảnh nhưng chỉ 241 ca ác tính. Mục 4.4 nêu rõ 61.663 ảnh ISIC chỉ chứa 61 ca ác tính, trong khi 377 ảnh PAD chứa 180 ca ác tính còn lại. Tức khoảng 0,6% số ảnh nằm gần ba phần tư số ca dương. Đồng thời, phần tóm tắt thừa nhận in-domain chỉ có 5/12 cặp có khoảng tin cậy loại trừ 0, thấp hơn nhiều so với HAM10000.

Why This Is Problematic: AUPRC phụ thuộc trực tiếp vào vị trí xếp hạng của các ca dương. Khi phần lớn ca dương tập trung trong một miền ảnh rất nhỏ, AUPRC toàn tập không còn phản ánh đều cả hai miền mà bị chi phối bởi năng lực xử lý PAD. Điều này không làm hỏng toàn bộ nghiên cứu, vì tác giả đã nhận diện vấn đề, nhưng nó làm suy yếu các câu kết luận tổng quát nếu người đọc chỉ nhìn AUPRC in-domain.

Potential Impact: Hội đồng có thể chất vấn rằng cải thiện in-domain của KD là hiệu ứng miền PAD chứ không phải cải thiện chung trên ảnh non-dermoscopic. Với chuẩn bài báo, reviewer có thể yêu cầu tách kết quả theo nguồn ảnh trước khi chấp nhận kết luận.

Recommended Fix: 1. Đưa phân rã theo nguồn ISIC/PAD lên sớm hơn, ngay sau Bảng 4.1–4.2, thay vì để như lời giải thích sau.

2. Báo cáo AUPRC, pAUC, Sens@90%Spec và CI riêng cho ISIC-test và PAD-test.
3. Với AUPRC toàn tập, thêm cảnh báo trong caption bảng rằng metric này bị chi phối bởi miền PAD do phân bố ca dương không đồng đều.
4. Nếu có thể, thêm bootstrap theo bệnh nhân hoặc theo nguồn ảnh để kiểm tra độ nhạy của kết luận khi PAD được lấy mẫu lại như một cụm thay vì từng ảnh.

Example Revision: Before: “KD cải thiện student theo hướng nhất quán trên toàn bộ 12 cặp ở các metric vận hành lâm sàng.”

After: “Trong miền, KD cho xu hướng cải thiện trên toàn bộ 12 cặp đối với $pAUC@TPR \geq 80\%$, nhưng bằng chứng thống kê ở AUPRC còn bị giới hạn bởi số ca dương nhỏ và cấu trúc test set lệch nguồn: 180/241 ca dương đến từ 377 ảnh PAD. Vì vậy, kết luận in-domain được xem là bằng chứng hỗ trợ; bằng chứng mạnh hơn đến từ HAM10000, nơi số ca dương lớn hơn và 11/12 cặp có CI loại trừ 0.”

Issue 2: Thiếu hiệu chuẩn xác suất và giao thức chọn ngưỡng triển khai

Category: Evaluation / Deployment

Severity: High

Evidence: Luận văn dùng Youden’s J để chọn ngưỡng và báo cáo các điểm Sens@90%Spec/Sens@95%Spec. Trên HAM10000, độ nhạy tại 90% specificity giảm rất mạnh so với trong miền; ví dụ nhiều run từ khoảng 0,95 trong miền giảm xuống khoảng 0,33–0,51 ngoài miền. Luận văn có nhắc hiệu chuẩn tiên cứu nằm ngoài phạm vi, nhưng không báo cáo ECE, Brier score, reliability diagram, calibration slope/intercept hoặc temperature scaling.

Why This Is Problematic: Với hệ thống sàng lọc y tế, ranking tốt chưa đủ. AUPRC và pAUC cho biết khả năng xếp hạng, nhưng ứng dụng thật cần ngưỡng ra quyết định và xác suất có ý nghĩa. Nếu ngưỡng chọn trong miền không chuyển được sang miền khác, tỷ lệ âm tính giả và dương tính giả trong triển khai sẽ thay đổi mạnh. Đây là khác biệt giữa “mô hình phân biệt được” và “mô hình dùng được như công cụ triage”.

Potential Impact: Đây là điểm yếu quan trọng nếu luận văn muốn bảo vệ luận điểm triển khai trên điện thoại. Hội đồng có thể chấp nhận vì tác giả đã giới hạn phạm vi lâm sàng, nhưng reviewer y tế hoặc Q1 sẽ yêu cầu calibration và threshold validation.

Recommended Fix:

1. Bổ sung ECE, Brier score, calibration curve và calibration slope/intercept cho in-domain, HAM10000 và Fitzpatrick17k.
2. Phân biệt rõ ba ngưỡng: ngưỡng chọn từ validation, ngưỡng báo cáo trên test, và ngưỡng triển khai cố định.
3. Thử temperature scaling hoặc Platt scaling trên validation, sau đó khóa tham số và chấm trên test/external.
4. Báo cáo decision table tại các mức specificity cố định: 90%, 95%, 98%, kèm số FP trên 1.000 ảnh và số FN trên 100 ca dương.

Example Revision: Before: “Ngưỡng quyết định nhị phân được chọn theo Youden’s J.”

After: “Youden’s J chỉ được dùng để mô tả điểm vận hành hậu nghiệm. Để mô phỏng triển khai, chúng tôi chọn ngưỡng trên validation của từng fold, khóa ngưỡng đó, rồi đánh giá trên held-out test và external datasets. Song song, chúng tôi báo cáo ECE và Brier score để tách năng lực xếp hạng khỏi độ tin cậy của xác suất.”

Issue 3: Tương quan $r = -0.963$ dễ bị hiểu là kết luận thống kê mạnh hơn dữ liệu cho phép

Category: Statistical Inference / Argumentation

Severity: High

Evidence: Phần tóm tắt nêu “khả năng tận dụng KD tỉ lệ nghịch với chất lượng sẵn có của student ($r = -0.963$, $n = 12$)”. Tuy nhiên, 12 điểm này không độc lập hoàn toàn: chúng dùng chung 4 student, 3 teacher, cùng held-out test, cùng pipeline tiền xử lý và cùng giao thức đánh giá.

Why This Is Problematic: Pearson correlation giả định các quan sát độc lập hoặc ít nhất không có cấu trúc phụ thuộc nghiêm trọng. Ở đây, mỗi student xuất hiện ba lần với ba teacher và mỗi teacher xuất hiện bốn lần với bốn student. Vì vậy, $n = 12$ phóng đại lượng thông tin độc lập. Kết quả có thể là xu hướng thực, nhưng cách viết hiện tại có nguy cơ khiến người đọc hiểu như một quy luật định lượng đã được xác nhận.

Potential Impact: Reviewer có nền thống kê có thể yêu cầu mô hình hỗn hợp hoặc phân tích theo cụm. Nếu không sửa, phát biểu này dễ bị xem là overclaim.

Recommended Fix: 1. Đổi câu khẳng định thành “xu hướng mô tả” hoặc “exploratory association”.

2. Báo cáo thêm phân tích theo student-level aggregation: lấy trung bình Δ của mỗi student qua ba teacher rồi so với baseline của student đó; lúc này $n = 4$ và chỉ nên mô tả, không kiểm định mạnh.
3. Nếu muốn giữ suy luận thống kê, dùng mô hình hỗn hợp: $\Delta \sim \text{baseline quality} + \text{random intercept}$ cho student và teacher.
4. Trình bày scatter plot với điểm được mã hóa theo student/teacher, không chỉ một hệ số r duy nhất.

Example Revision: Before: “Khả năng tận dụng KD tỉ lệ nghịch với chất lượng sẵn có của student ($r = -0.963$, $n = 12$).”

After: “Trên 12 cặp teacher–student, Δ do KD có xu hướng giảm khi baseline của student mạnh hơn. Do các điểm chia sẻ student, teacher và tập test, hệ số $r = -0.963$ chỉ được xem là mô tả exploratory, không phải kiểm định độc lập của một quy luật tổng quát.”

Issue 4: Baseline đối chứng chưa bao phủ đủ các lựa chọn nén và triển khai thay thế

Category: Evaluation / Novelty

Severity: High

Evidence: Thiết kế chính so sánh mỗi student KD với chính student không KD, đây là baseline bắt buộc và được làm tốt. Tuy nhiên, luận văn chưa đặt KD cạnh các lựa chọn cạnh tranh như label smoothing thường, class-balanced/focal variants, pruning, quantization-aware training, post-training quantization, hoặc các kiến trúc mobile kinh điển như MobileNetV3/EfficientNet-Lite trong cùng giao thức.

Why This Is Problematic: Câu hỏi nghiên cứu hiện tại chứng minh “KD có giúp so với no-KD hay không”, nhưng chưa chứng minh “KD là lựa chọn triển khai tốt hơn các kỹ thuật edge optimization khác”. Vì luận văn đặt động lực ở nghịch lý chính xác–triển khai, reviewer có thể kỳ vọng một khung baseline rộng hơn cho bài toán edge AI.

Potential Impact: Đối với bảo vệ thạc sĩ, điểm này không phủ định đóng góp vì khung ceteris paribus đã tốt. Nhưng để chuyển thành paper mạnh, thiếu baseline thay thế sẽ làm đóng góp KD bị xem là hẹp.

Recommended Fix: 1. Thêm một baseline “label smoothing không teacher” để kiểm tra giả thuyết KD trong binary one-logit thực chất là adaptive label smoothing.

2. Thêm một baseline “same student + class-balanced loss” hoặc “focal loss variants” để tách tác dụng KD khỏi tác dụng regularization.

3. Nếu tài nguyên cho phép, thêm PTQ INT8 hoặc QAT cho hai mô hình Pareto, vì đó là đối thủ triển khai trực tiếp của FP32 KD.
4. Báo cáo bảng “accuracy–latency–size” có các cột: no-KD, KD, label smoothing, quantization/pruning nếu có.

Example Revision: Before: “KD là lời giải cho khoảng cách giữa mô hình lớn và thiết bị biên.”

After: “Trong phạm vi luận văn, KD được chứng minh là cải thiện student so với nhánh huấn luyện không KD dưới cùng kiến trúc và cùng giao thức. Kết luận này chưa thay thế cho so sánh với các kỹ thuật nén khác như quantization, pruning hoặc label smoothing; các kỹ thuật này được xem là baseline mở rộng cho nghiên cứu tiếp theo.”

Issue 5: Thiếu phân tích lỗi ca bệnh và bằng chứng giải thích mô hình

Category: Evaluation / Clinical Validity

Severity: Medium

Evidence: Luận văn báo cáo nhiều metric tổng hợp, phân rõ theo miền, phân tích cross-domain và fairness. Tuy nhiên, bản thảo chưa thấy phần error analysis theo ca bệnh: ví dụ các false negative có đặc điểm tổn thương nào, thuộc nguồn ảnh nào, kích thước/ánh sáng/tông da nào; cũng không có Grad-CAM, saliency, occlusion test hoặc phân tích mẫu khó.

Why This Is Problematic: Trong bài toán ung thư da, lỗi âm tính giả có hậu quả lớn hơn lỗi dương tính giả. Metric tổng hợp không cho biết mô hình bỏ sót kiểu tổn thương nào và có đang dựa vào nhiều nền, màu da, ánh sáng, thước đo hoặc artefact chụp ảnh hay không. Đối với CAD y tế, error taxonomy là cầu nối giữa kết quả ML và tính đáng tin cậy lâm sàng.

Potential Impact: Hội đồng có thể hỏi: “Những ca ác tính bị bỏ sót trông như thế nào?” hoặc “KD cải thiện bằng cách học tổn thương hay học domain cue?” Nếu không có phân tích lỗi, phần diễn giải cơ chế còn thiếu.

Recommended Fix:

1. Thêm một mục “Error Analysis” sau kết quả chính.
2. Chọn top false negatives và top false positives của hai mô hình Pareto, trình bày theo nguồn ảnh, tông da, loại tổn thương nếu có, và confidence.
3. Thêm Grad-CAM/Score-CAM hoặc occlusion sensitivity cho một tập mẫu đại diện để kiểm tra mô hình chú ý vào vùng tổn thương.
4. Định lượng lỗi theo nhóm: source, lesion type, skin tone, brightness/blur proxy, và fold.

Example Revision: Before: “Mô hình A có AUPRC cao hơn mô hình B.”

After: “Ngoài AUPRC, chúng tôi phân tích 50 false negatives có xác suất thấp nhất trong nhóm ác tính. Phần lớn lỗi tập trung ở ảnh PAD thiếu sáng và tổn thương nhỏ; bản đồ saliency cho thấy một số mẫu bị mô hình chú ý vào nền da thay vì vùng tổn thương. Điều này giải thích vì sao AUPRC tăng nhưng ngưỡng triển khai vẫn không ổn định khi chuyển miền.”

Issue 6: Phân tích công bằng còn thiên về metric tổng hợp, chưa đủ cho quyết định vận hành

Category: Fairness / Evaluation

Severity: Medium

Evidence: Luận văn dùng Fitzpatrick17k và chỉ ra khoảng cách tái lập được chủ yếu là light-medium, không phải light-dark. Appendix cho thấy dark group có số mẫu nhỏ hơn rõ rệt so với light và medium, và nhiều khoảng cách dark-related không loại trừ 0. Luận văn cũng đã cảnh báo việc so AUPRC giữa nhóm có prevalence khác nhau có thể gây kết luận sai.

Why This Is Problematic: Fairness trong hệ thống sàng lọc không chỉ là AUC/AUPRC trung bình. Người dùng chịu tác động bởi quyết định ở một ngưỡng cụ thể: cùng specificity, nhóm nào bị bỏ sót nhiều hơn? Nếu ngưỡng chung làm một nhóm có FN cao hơn, mô hình có thể gây bất lợi thực tế dù AUPRC chênh không lớn.

Potential Impact: Phần fairness hiện đã tốt hơn mức trung bình, nhưng vẫn chưa đủ nếu luận văn muốn tuyên bố về công bằng thuật toán theo nghĩa vận hành. Reviewer có thể yêu cầu equal opportunity gap, false negative rate gap và threshold-specific analysis.

Recommended Fix:

1. Báo cáo Sens@90%Spec và Sens@95%Spec theo từng nhóm Fitzpatrick.
2. Báo cáo FNR gap, FPR gap và confidence interval của gap tại một ngưỡng cố định.
3. Nêu rõ độ tin cậy của kết luận dark group bị giới hạn bởi kích thước mẫu nhỏ và nhãn Fitzpatrick có thể nhiễu.
4. Tránh khuyến nghị ngưỡng riêng theo nhóm nếu chưa có phân tích đạo đức/pháp lý; chỉ trình bày như phân tích nguy cơ.

Example Revision: Before: “Khoảng cách tái lập được là light-medium.”

After: “Ở mức ranking, khoảng cách ổn định nhất là light-medium. Tuy nhiên, để đánh giá rủi ro vận hành, chúng tôi bổ sung Sens@95%Spec và FNR gap theo từng nhóm tông da tại cùng ngưỡng triển khai. Các kết luận liên quan tới nhóm dark được diễn giải thận trọng do cỡ mẫu nhỏ và khoảng tin cậy rộng.”

Issue 7: Phụ lục siêu tham số tốt nhưng gói tái lập vẫn chưa đủ chặt

Category: Reproducibility

Severity: Medium

Evidence: Phụ lục B cung cấp nhiều thông tin quan trọng: kích thước ảnh, split, seed, sampler, backbone, optimizer, LR, scheduler, batch size, loss, callback, bootstrap và benchmark. Tuy nhiên, bản luận văn chưa thấy repository URL, commit hash, file requirements/conda, Docker image, phiên bản

Python/PyTorch/CUDA/timm chính xác, cấu trúc thư mục artifact và checksum của split/prediction files.

Why This Is Problematic: Trong học sâu, “timm ≥ 1.0 ” hoặc “trọng số ImageNet” chưa đủ để lặp lại kết quả, vì pretrained weight tag, transform mặc định, operator lowering và backend có thể thay đổi theo phiên bản. Luận văn đã hiểu vấn đề này khi nhắc weight tag, nhưng cần đóng vòng tái lập bằng manifest thực thi được.

Potential Impact: Hội đồng thạc sĩ thường chấp nhận nếu tác giả trình diễn code nội bộ, nhưng bản PDF độc lập vẫn chưa đủ để một nhóm khác tái chạy. Với chuẩn công bố, đây là điểm major revision về reproducibility.

Recommended Fix:

1. Thêm phụ lục “Reproducibility Package” gồm repository, commit hash, command chạy từng pha, môi trường và cấu trúc thư mục.
2. Pin phiên bản: Python, PyTorch, torchvision, timm, sklearn, albumentations, ExecuTorch, Android build toolchain.
3. Công bố checksum của các split CSV, prediction CSV và model checkpoints quan trọng.
4. Ghi rõ pretrained weight tag đầy đủ cho từng backbone nếu chưa nằm trong bảng chính.

Example Revision: Before: “Mọi số liệu đều truy vết được về artifact do các lượt chạy sinh ra trên đĩa.”

After: “Mọi số liệu trong Chương 4 có thể tái dựng từ gói artifact kèm theo gồm: commit <hash>, environment.yml, splits/*.csv kèm SHA256, predictions/*.csv, checkpoints/*.pth, và script reproduce_tables.py. Bảng B.8 liệt kê checksum của các artifact dùng để sinh từng bảng/hình.”

Issue 8: Phạm vi lâm sàng được rào tốt, nhưng workflow an toàn người dùng còn thiếu

Category: System Design / Clinical Risk

Severity: Medium

Evidence: Luận văn nói rõ đây là đánh giá hồi cứu và chưa sẵn sàng cho sử dụng lâm sàng. Tuy vậy, vì đề tài nhắm tới sàng lọc trên điện thoại, bản thảo chưa mô tả đủ workflow an toàn: cảnh báo người dùng, human-in-the-loop, xử lý ảnh không hợp lệ/OOD, yêu cầu chụp lại, luồng giới thiệu đi khám, và giới hạn trách nhiệm khi mô hình trả kết quả âm tính.

Why This Is Problematic: Với ứng dụng y tế trên thiết bị biên, rủi ro không chỉ nằm ở model metric. Người dùng có thể hiểu “âm tính” là an toàn và trì hoãn khám. Ngoài ra, ảnh đầu vào ngoài phân phối như hình xăm, vết thương, ảnh mờ, ảnh vật thể không phải da hoặc ánh sáng xấu có thể sinh kết quả tự tin giả.

Potential Impact: Luận văn vẫn bảo vệ được về kỹ thuật, nhưng thiếu lớp safety design làm giảm tính hoàn chỉnh của hệ thống triển khai.

- Recommended Fix:**
1. Thêm sơ đồ workflow triển khai: kiểm tra chất lượng ảnh → dự đoán → thông báo rủi ro → khuyến nghị khám chuyên khoa nếu vượt ngưỡng hoặc ảnh không đạt chất lượng.
 2. Thêm OOD/quality gate tối thiểu: blur, over/under-exposure, skin-region check hoặc confidence rejection.
 3. Diễn đạt đầu ra là “mức ưu tiên sàng lọc” thay vì “chẩn đoán ung thư”.
 4. Nêu rõ false-negative policy: kết quả thấp không thay thế khám bác sĩ nếu tổn thương thay đổi nhanh, chảy máu, đau, hoặc có dấu hiệu ABCDE.

Example Revision: Before: “Ứng dụng phát hiện ung thư da trên điện thoại.”

After: “Hệ thống được định vị như công cụ hỗ trợ sàng lọc ban đầu, không phải công cụ chẩn đoán. Ứng dụng chỉ trả mức ưu tiên khám và luôn hiển thị khuyến cáo: kết quả nguy cơ thấp không loại trừ bệnh; người dùng cần khám chuyên khoa nếu tổn thương thay đổi, đau, chảy máu hoặc có dấu hiệu ABCDE.”

Issue 9: Một số phát biểu về “tốt nhất hiện có” và “duy nhất” cần được rào theo phạm vi tìm kiếm

Category: Argumentation / Novelty

Severity: Medium

Evidence: Luận văn nhiều lần dùng các cách diễn đạt mạnh như “kiến trúc tốt nhất hiện có”, “bộ dữ liệu công khai duy nhất đáp ứng”, hoặc “teacher nào tốt nhất”. Các câu này có thể đúng trong phạm vi tác giả khảo sát, nhưng nếu không nêu rõ tiêu chí và thời điểm, chúng dễ bị đọc như tuyên bố tuyệt đối.

Why This Is Problematic: Trong nghiên cứu CS/AI, SOTA thay đổi nhanh và phụ thuộc benchmark, input resolution, pretrained weights, latency backend và metric. Phát biểu tuyệt đối mà không gắn với tiêu chí có thể bị reviewer bắt lỗi ngay cả khi phần thực nghiệm chính vẫn tốt.

Potential Impact: Làm giảm độ tin cậy của phần positioning và novelty. Với hội đồng, câu hỏi phản biện có thể là: “Tốt nhất theo benchmark nào? Tại thời điểm nào? Trên thiết bị nào?”

- Recommended Fix:**
1. Thay “tốt nhất hiện có” bằng “đại diện mạnh gần đây cho bốn paradigm thiết kế theo tiêu chí tham số/FLOPs/latency và khả dụng trong tìm kiếm tại thời điểm thực nghiệm”.
 2. Với dữ liệu, thay “duy nhất” bằng “trong phạm vi các bộ công khai được khảo sát, ISIC 2024 là bộ phù hợp nhất với ba tiêu chí...”
 3. Thêm bảng tiêu chí chọn backbone: năm công bố, tham số, FLOPs, weight availability, hỗ trợ export, vai trò teacher/student.

Example Revision: Before: “Bốn student đều là kiến trúc tốt nhất hiện có cho thiết bị biên.”

After: “Bốn student được chọn như các đại diện mạnh và gần đây cho bốn paradigm thiết kế edge-vision, với điều kiện có trọng số pretrained công khai,

hỗ trợ triển khai trong pipeline PyTorch/ExecuTorch và có quy mô phù hợp với thiết bị di động.”

Issue 10: Bản thảo còn lỗi hoàn thiện hình thức trước khi nộp chính thức

Category: Writing / Formatting

Severity: Low

Evidence: Trang bìa còn ghi “logo Trường — chèn ở bước xuất bản Word”, lời cam đoan còn ngày tháng dạng placeholder, và mục “DANH MỤC CÔNG BỐ KHOA HỌC CỦA TÁC GIẢ” còn ghi “CẦN ĐIỀN”. Một số bảng dài bị ngắt dòng mạnh do xuất PDF từ Google Docs, làm tên mô hình và số liệu khó đọc.

Why This Is Problematic: Đây không phải lỗi khoa học, nhưng là lỗi nộp luận văn. Các placeholder làm bản thảo trông chưa hoàn tất và có thể tạo ấn tượng thiếu kiểm soát chất lượng.

Potential Impact: Có thể bị yêu cầu sửa hình thức trước khi bảo vệ/nộp thư viện, dù nội dung kỹ thuật đủ mạnh.

Recommended Fix: 1. Điền ngày tháng, chèn logo, hoàn thiện danh mục công bố hoặc ghi “Không có” nếu đúng.

2. Rà toàn bộ bảng rộng; với bảng số liệu chính, nên dùng landscape page hoặc phụ lục bảng đầy đủ ở dạng longtable.

3. Chuẩn hóa tên mô hình để không bị cắt giữa dòng; cân nhắc dùng MobileNetV4-Conv-Medium, EfficientFormerV2-S2 trong font monospace nhỏ hơn.

4. Kiểm tra lại danh mục tài liệu tham khảo theo chuẩn trường: dấu câu, DOI, access date, italic journal title, volume/issue.

Example Revision: Before: “DANH MỤC CÔNG BỐ KHOA HỌC CỦA TÁC GIẢ: (CẦN ĐIỀN).”

After: “DANH MỤC CÔNG BỐ KHOA HỌC CỦA TÁC GIẢ: Chưa có công bố liên quan trực tiếp đến luận văn tại thời điểm nộp.” hoặc liệt kê đúng bài báo nếu đã có.

FINAL VERDICT

- **Publication Readiness: 7.0/10.** Luận văn có nền thực nghiệm mạnh, thiết kế kiểm soát tốt và phần triển khai biên đáng giá. Tuy nhiên, để chuyển thành bài journal mạnh hoặc Q1-oriented paper, cần bổ sung calibration/threshold protocol, baseline nén thay thế, error analysis và gói tái lập. Nếu chỉ rút thành conference paper về KD cho edge dermatology, khả năng tốt hơn sau major revision có trọng tâm.

- **Defense Readiness: 8.5/10.** Công trình đủ mạnh để bảo vệ thạc sĩ sau khi sửa các lỗi hình thức và rào lại một số phát biểu quá mạnh. Các điểm yếu còn lại chủ yếu là mở rộng phân tích và diễn giải, không phải lỗi phá vỡ phương pháp.
- **Decision: Minor Revision for thesis defense; Major Revision for publication extraction.** Với mục tiêu bảo vệ thạc sĩ, nên cho phép bảo vệ sau khi sửa hình thức, bổ sung rào giới hạn in-domain, và thêm một trang calibration/threshold limitation. Với mục tiêu công bố, cần major revision vì baseline thay thế và calibration là yêu cầu quan trọng.

Priority Revision Checklist

1. Sửa ngay placeholder: logo, ngày cam đoan, danh mục công bố, bảng bị vỡ dòng.
2. Viết lại abstract/conclusion để phân biệt rõ: bằng chứng in-domain hỗ trợ, bằng chứng HAM10000 mạnh hơn, chưa có kết luận lâm sàng tiến cứu.
3. Thêm bảng phân rã ISIC vs PAD cho AUPRC/pAUC/Sens@90%Spec.
4. Bổ sung ECE, Brier score, reliability diagram và mô tả chiến lược ngưỡng triển khai.
5. Đổi phát biểu $r = -0.963, n = 12$ thành xu hướng mô tả do cấu trúc phụ thuộc giữa các cặp.
6. Thêm ít nhất một baseline “label smoothing không teacher” để kiểm tra cơ chế KD trong bài toán binary one-logit.
7. Thêm mục error analysis gồm false negative/false positive tiêu biểu và phân tích theo nguồn ảnh/tông da.
8. Bổ sung phụ lục tái lập: repository, commit, environment, command, checksum split/prediction.